



(S)ARIMA(X)

Klassische Methoden für
Business Prognosis

Von Antoine Hunou, Deborah Lang
und Marius Riesle

Am 26. Juni 2026


Gliederung

1. Einführung: Forecasting im Business Kontext
2. Grundlagen: Zeitreihen
3. ARIMA
4. SARIMA
5. SARIMAX
6. Vergleich, Grenzen & praktische Anwendung von (S)ARIMA(X)



Einführung

Forecasting



Warum Forecasting?

„Es gibt keine Chance, dass das iPhone jemals einen signifikanten Marktanteil gewinnen wird. Keine Chance.“

Steve Ballmer 2007 (damaliger Microsoft-Chef)


- Menschen versuchen schon immer, die Zukunft vorherzusagen – oft mit mäßigem Erfolg.
- Wann funktioniert Forecasting?
 - ✓ Wenn wir die **Einflussfaktoren** verstehen.
 - ✓ Wenn genug **historische Daten** vorliegen.
 - ✓ Die **Zukunft** der **Vergangenheit** ähnelt.
 - ✓ Die Prognose das Ergebnis **nicht beeinflusst**.
- Drei wichtige Begriffe des Forecasting:
 - **Goals / Ziele:** Was soll erreicht werden? Ohne Plan und Prognose oft unrealistisch.
 - **Forecasting / Prognose:** Datengetriebene Vorhersage der Zukunft.
 - **Planning / Planung:** Maßnahmen, um Forecasting-Erwartungen mit den Zielen in Einklang zu bringen.



Ziel von Modellen wie ARIMA: Den wahrscheinlichsten Zukunftswert (Point Forecast) berechnen und die Unsicherheit (Prediction Interval) angeben.

Grundlagen

Zeitreihen




Zeitreihen

- Eine Zeitreihe ist eine Folge von Beobachtungen, die **chronologisch** gemessen werden.

$$Y = (y_1, y_2, y_3, \dots, y_t)$$

- **Trend:** Langfristige Richtung (steigend/fallend)
 - Beispiel: Stetig steigender Energiebedarf
- **Saisonalität:** Muster, die sich in festen Intervallen wiederholen.
 - Beispiel: Eiscreme-Verkauf über das Jahr hinweg
- **Zyklus:** Wiederkehrendes Muster ohne feste Frequenz.
 - Beispiel: Konjunkturzyklus der Wirtschaft
 - Oft mit Trend zusammengefasst
- **Zufallskomponente:** Unvorhersehbares „Rauschen“, das nach Abzug der anderen Komponenten übrig bleibt.
 - Beispiel: Corona-Pandemie



<https://medium.com/@kis.andras.nandor/demystifying-stl-understanding-seasonal-decomposition-of-time-series-d3c50150ec12>

Voraussetzungen für Prognosemodelle

1. Autokorrelation


Misst, wie stark ein Wert y_t von seinen eigenen vergangenen Werten (Lags, z. B. y_{t-1}) abhängt.

- *Beispiel: Das Wetter heute korreliert stark mit dem Wetter gestern.*

2. Stationarität


Eine Zeitreihe ist *stationär*, wenn sich ihre statistischen Eigenschaften über die Zeit **nicht** verändern:

- Konstanter Erwartungswert
 - Mittelwert, kein Trend.
- Konstante Varianz
 - Schwankungsbreite bleibt gleich.
- Konstante Autokovarianz
 - Abhängigkeit hängt nur vom Zeitabstand ab, nicht vom absoluten Zeitpunkt.



ARIMA

Vorstellung des Modells



Eine der mächtigsten klassischen Prognosemethoden


Das ARIMA-Modell



Entwickelt in den 1970er
(Box-Jenkins-Methode)




Soll komplexe zeitliche
Abhängigkeiten
mathematisch modellieren



Funktioniert nur mit
stationären Daten!

ARIMA sagt die Zukunft voraus, indem es Muster und Fehler aus der Vergangenheit lernt.

Die Bausteine im Detail



Auto Regressive

Ziel:

Einfluss der Vergangenheit modellieren.

Konzept:

Der Wert heute hängt von früheren Werten ab

$$y_t = c + \phi_1 y_{t-1} + \dots + \varepsilon_t$$

Parameter:

p (Anzahl der Lags)

Gefahr:

Overfitting, wenn p zu groß gewählt wird



Integrated

Ziel:

Stationarität herstellen.

Konzept:

Differenzieren

$$\Delta = y_t - y_{t-1}$$

Parameter:

d (Anzahl der Differenzierungen)



Moving Average

Ziel:

Auswirkungen von zufälligen Ereignissen/Fehlern modellieren.

Konzept:

Der Wert heute hängt von unvorhersehbaren „Schocks“ der Vortage ab

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

Parameter:

q (Anzahl der Fehler – Lags)




Wie ARIMA funktioniert

1

Ausgangsreihe


Nicht-stationäre Zeitreihe
mit Trend oder
wechselndem Niveau



2

I = Integrated


Differenzieren, bis die
Reihe stationär ist
 $\Delta y_t = y_t - y_{t-1}$



3

AR + MA


AR(p): vergangene Werte
beeinflussen y_t
MA(q): vergangene Fehler
beeinflussen y_t



4

Ergebnis

Forecast der nächsten
Werte inkl. Unsicherheit
durch Prognoseintervalle




Wie man geeignete Parameter findet

$$ARIMA(p, d, q)$$

$p(AR)$	Wie viele Lags (vergangene Werte) schauen wir uns an?
$d(I)$	Wie oft müssen wir differenzieren, bis die Daten stationär sind?
$q(MA)$	Wie viele Schocks (vergangene Fehler) beziehen wir ein?

1. Der klassische Weg (Box-Jenkins)

- Analyse von **ACF** (Autokorrelation) und **PACF** (Partielle Autokorrelation)



2. Der moderne Weg (Automatisiert)

- Auto-ARIMA** (z.B. Hyndman-Khandakar Algo): Testet systematisch Kombinationen durch, um das beste Modell zu finden.
- Bewertung über Informationskriterien **AIC** / **BIC**. Je kleiner der Wert, desto Besser das Modell.

Validierung

1. Residuenanalyse

- Wichtigster Check (meist **Ljung-Box-Test**)
- Gibt den Fehler an, den das Modell in der Vergangenheit gemacht hat.
- *Ziel:* Die Residuen müssen **White Noise** sein.
- Es darf kein erkennbares Muster mehr in den Fehlern stecken.



Ljung-Box-Test

Prüft mathematisch, ob die Residuen der Zeitreihe unabhängig voneinander sind.

Nullhypothese H_0 : Die Daten sind unabhängig voneinander verteilt.

p-Wert > 0,05 (Signifikanzniveau)


→ Nullhypothese wird nicht verworfen. Die Residuen sind White Noise.

p-Wert < 0,05

→ Nullhypothese wird verworfen. Es gibt noch Autokorrelationen in den Residuen.

2. Forecast-Intervalle

- Point Forecast vs. Realität: Die Vorhersage eines exakten Einzelwerts ist in der Praxis fast immer falsch.
- Forecast-Verteilung: Stattdessen werden mögliche Zukunftswerte und deren Wahrscheinlichkeit berechnet.
- Das Intervall: Daraus leitet sich die Prediction Intervals ab (z.B. „Mit 95% Wahrscheinlichkeit liegt der Umsatz zwischen X und Y.“)
- Damit werden Unsicherheiten kommuniziert.
- ARIMA liefert **Konfidenzintervalle**
- Je weiter wir in die Zukunft blicken, desto breiter wird das Intervall, da die Unsicherheit zunimmt.



Point Forecast:

$$\hat{y}_{t+h}$$

Forecast-Verteilung:

$$Y_{t+h} \sim N(\hat{y}_{t+h}, \sigma_h^2)$$

Typische Use-Cases



Supply Chain & Nachfrageplanung

Wie viele Produkte müssen nächste Woche auf Lager sein?



Absatz & Umsatzprognose

Budgetplanung für das nächste Quartal



Energieverbrauch

Vorhersage der Stromlast (extrem saisonal/zyklisch)




Finanzzeitreihen


Prognose von Aktien-Volatilitäten oder Zinsentwicklungen

SARIMA

Erweiterung
um saisonale Muster



Warum reicht ARIMA nicht?




ARIMA

ARIMA


1

Nach ARIMA Differenzierung enthält Muster





2

ARIMA Residuen zeigen Muster





Konzept von SARIMA

Nicht-saisonal



Saisonal



Wie funktioniert SARIMA?

$$SARIMA(p, d, q) (P, D, Q)m$$

Nicht-saisonale Komponente

$p(AR)$	Wie viele Lags (vergangene Werte) schauen wir uns an?
$d(I)$	Wie oft müssen wir differenzieren, bis die Daten stationär sind?
$q(MA)$	Wie viele Schocks (vergangene Fehler) beziehen wir ein?

Saisonale Komponente

$P(AR)$	Wie viele Lags der letzten Saisonen schauen wir uns an?
$D(I)$	Wie oft müssen wir saisonal differenzieren, bis die Daten stationär sind?
$Q(MA)$	Wie viele Schocks der letzten Saisonen beziehen wir ein?
m	Saisonlänge

Wie funktioniert SARIMA?

$$SARIMA(p, d, q) (P, D, Q)m$$

Auto Regressive

Einfluss der Vergangenheit

Nicht-saisonal

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t$$

Saisonal

$$y_t = c + \Phi_1 y_{t-s} + \varepsilon_t$$

Kombiniert

$$y_t = c + \phi_1 y_{t-1} + \Phi_1 y_{t-s} + \varepsilon_t$$

Integrated

Stationarität herstellen

Nicht-saisonal

$$\Delta = y_t - y_{t-1}$$

Saisonal

$$\Delta = y_t - y_{t-s}$$

Kombiniert

$$\Delta = (y_t - y_{t-1}) - (y_t - y_{t-s})$$

Moving Average

Auswirkungen von Fehlern

Nicht-saisonal

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

Saisonal

$$y_t = \mu + \varepsilon_t + \Theta_1 \varepsilon_{t-s}$$

Kombiniert

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-s}$$

Limitationen & Use Cases



Benötigt ausreichend historische Daten



Sensibel gegenüber Strukturbrüchen und instabiler Saisonalität




Schwächer bei mehreren überlagerten Saisonalitäten



Berücksichtigt externen Einflüsse nicht


Anwendung für **saisonale Zeitreihen** mit **regelmäßigem Muster**.

Beispiel:
Umsatz von Amazon pro Quartal




SARIMAX

Erweiterung
um exogene Einflussfaktoren



Warum reicht SARIMA oft nicht aus?

- Problem: exogene Einflussfaktoren → SARIMAX



Wie funktioniert SARIMAX?

- Formel:

$$y_t = \beta_0 + \sum_{i=1}^I \beta_i X_{i,t} + n_t$$


→ Regression mit SARIMA Errors
 $n_t \sim \text{SARIMA}(p, d, q)(P, D, Q)_m$

- Parameterschätzung mittels Maximum-Likelihood
- Moderne Implementierung: State-Space-Modell mit Kalman Filter
- Modenannahmen:


$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

mit Zielvariablen y_t ,
exogenen Variablen $X_{i,t}$,
geschätzten Einflussstärken β_i
& Fehlerterm n_t


mit $\varepsilon_t \sim \text{WN}(0, \sigma^2)$



Linearer Zusammenhang



Stationäre Residuen



Keine starke Multikollinearität

Feature Selection

& Feature Engineering

Welche exogenen Variablen sollen im Modell verwendet werden?



Fachliche Relevanz:
Domänenwissen



Zusammenhang mit der Zielgröße:
Korrelation & Signifikanztests



Redundanz zwischen Variablen:
VIF



Beitrag zum Gesamtmodell:
AIC/BIC

Wie können die vorhandenen, exogenen Variablen besser genutzt werden?

- Lagged Features: verzögerte Effekt
 $\text{Temp}_t \rightarrow \text{Temp}_{t-1}$
- Rolling Features: kurzfristige Schwankungen
 $\text{Temp} \rightarrow \text{MA}_7(\text{Temp})$
- Kalenderfeatures: wiederkehrende Muster
 $\text{Datum} \rightarrow \text{Wochentag}/\dots$
- Interaktionsfeatures: gemeinsame Effekte
 $X_1 \times X_2$
- Transformationen: nicht lineare Effekte
 $X \rightarrow X^2$

→ Prognosequalität hängt von Auswahl & Aufbereitung geeigneter exogener Variablen ab
→ Exogene Variablen verbessern Prognosegenauigkeit über historische Nachfrage hinaus

Limitationen & Use Cases

Limitationen



Prognosequalität abhängig von
Zukunftswerte exogener Variablen



Nichtlinearitäten



Korrelation $\neq$ Kausalität




Verzögerte exogene Variablen

Use Cases

- Energieprognosen
(Wetterdaten)
- Retail Sales Forecasting
(Preis, Promotionen, Feiertage)
- Marketing Forecasting
(Werbekampagnen, Rabatte)
- Supply Chain Forecasting
(Nachfrage, Wirtschaftsdaten)

→ SARIMAX verbessert Forecasts nur, wenn exogenen Variablen relevant, verfügbar & korrekt modelliert

Vergleich, Grenzen & praktische Anwendung von (S)ARIMA(X)



Wann wird (S)ARIMA(X) für Business Forecasting gewählt?



Grenzen aller Modelle

Strukturbrüche



Datenqualität

Nichtlinearitäten



Forecast Drift



Warum ist (S)ARIMA(X) auch heute noch relevant?



Einfach



robust




interpretierbar



geringe Datenmengen ausreichen


Live-Demo

Forecast des Strombedarf




Hands-on Übung

Forecast des
täglichen Hausverbrauchs
(kWh/Tag)



Fragen & Diskussion



Quellen

- Hyndman, R.J. & Athanasopoulos, G. (2024). Forecasting: Principles and Practice:
 - [Forecasting: Principles and Practice \(3rd ed\)](#)
 - [Forecasting: Principles and Practice \(2nd ed\)](#)
- Brockwell, J. P. & Davis R. A. (2016). Introduction to Time Series and Forecasting (Thrid Edition):
https://eprints.ukh.ac.id/id/eprint/232/1/2016_Book_IntroductionToTimeSeriesAndFor.pdf
- Kuhn, M. & Johanson, K. (2018). Feature Engineering and Selection: A Practical Approach for Predictive Models:
[Feature Engineering and Selection: A Practical Approach for Predictive Models](#)
- Quelle des Datensatzes:
[Renewable Energy and Electricity Demand Time Series Dataset with Exogenous Variables at 5-minute Interval — OpenEnergyDataPortal](#)